

Etapa 3 Limpieza SSIS

José Daniel Gómez Rodríguez

Manuel Felipe Murcia Suarez

Carlos Julio Pérez Rodríguez

Universidad de Cundinamarca – Extensión Chía

Minería de Datos

Edison Gustavo Cañon Varela

Introducción y Alcance

Este informe documenta el diseño, la implementación y la validación del paquete SSIS de la solución de nuestro proyecto sobre enfermedades transmitidas por vectores. El paquete extrae datos de tres fuentes relacionadas con enfermedades, los conserva sin alteraciones en una zona de staging dentro de la base DB_ENFERMEDADES_ETV que hicimos en SQL Express y aplica reglas de limpieza, estandarización, detección de duplicados y validación de valores atípicos antes de cargar los datos en tablas finales.

El principio rector es que ningún registro se pierde sin explicación: lo que se elimina se contabiliza, lo dudoso se separa en una tabla de revisión con su valor original, y el dato crudo siempre permanece en staging para poder repetir el proceso.

Fuente	Tipo de origen	Tabla de staging	Destino tratado	Filas recibidas
Perfil clínico	Tabla SQL (OLE DB)	dbo.stg_perfil_clinico	dbo.tbl_perfil_clinico_final dbo.tbl_revision_calidad	1.377.630
SIVIGILA Nacional y Cundinamarca	Archivo plano CSV	dbo.stg_regional_cundinamarca	Staging con tipos convertidos	1.640
OMS – Brotes (Datasets globales)	Archivo plano CSV	dbo.stg_oms_brotes	Staging con tipos convertidos	3.566

Diagnostico Inicial y Reglas


A partir del diagnóstico de calidad de la etapa 2 y de las transformaciones implementadas en el paquete, se consolidaron los problemas de calidad detectados. Para cada uno se definió el campo afectado, la acción de tratamiento y su justificación.

#	Problema	Campo(s) afectado(s)	Acción definida	Justificación
R1	Registros duplicados	Registro completo del perfil clínico (stg_perfil_clinico)	Ordenar con Sort y eliminar las filas con valores de ordenación duplicados; contabilizar la diferencia entre filas de entrada y salida.	Los duplicados inflan los conteos y sesgan los indicadores epidemiológicos. El original permanece en staging, por lo que la eliminación es trazable.
R2	Valores nulos o vacíos	SEXO	Derived Column <i>sexo_limpio</i> : si el valor es nulo se reemplaza por un valor por defecto; en caso contrario se estandariza.	Evita categorías vacías en agrupaciones y garantiza un dominio completo del campo.
R3	Valores nulos o vacíos	REGIMEN_AFILIACION	Derived Column <i>regimen_limpio</i> : expresión condicional con reemplazo del nulo.	Mismo criterio que R2: la variable se usa como dimensión de análisis.
R4	Formato inconsistente (mayúsculas/minúsculas, espacios)	SEXO, REGIMEN_AFILIACION	Aplicar TRIM y UPPER dentro de la expresión de la columna derivada.	Categorías como "F", "f" o "F " deben contarse como una sola.
R5	Tipo de dato inadecuado	EDAD	Conversión con (DT_I4)EDAD a la columna <i>edad_int</i> .	Un tipo numérico permite validar rangos y calcular grupos etarios.

#	Problema	Campo(s) afectado(s)	Acción definida	Justificación
R6	Valores inválidos o atípicos	edad_int	Conditional Split: válido si $0 \leq \text{edad} \leq 110$; el resto (incluye nulos) va a <i>Registros_Atipicos</i> → <i>tbl_revision_calidad</i> .	Edades negativas o superiores a 110 años no son plausibles; se separan para revisión sin descartarlas.
R7	Longitud y página de códigos	COD_CIE10	Cast a (DT_STR, 10, 1252) → <i>cod_cie10_corto</i> .	Ajusta el código CIE-10 a una longitud controlada y a la página de códigos 1252.
R8	Longitud y página de códigos	NACIONALIDAD	Cast a (DT_STR, 50, 1252) → <i>nacionalidad_cast</i> .	Homogeneiza el tipo con el destino y evita truncamientos silenciosos.
R9	Longitud y página de códigos	NOMBRE_CIE10	Cast a (DT_STR, 250, 1252) → <i>cie10_diagnostico_cast</i> .	Los nombres de diagnóstico son largos; se reserva 250 caracteres.
R10	Tipos de dato en archivo plano (SIVIGILA)	anio, conteo, cod_municipio, municipio, evento, LETALIDAD..., TASA DE INCIDENCIA...	Data Conversion: anio y conteo a entero de 4 bytes; cod_municipio (20), municipio (100), evento (100) y las dos tasas (50) como cadena.	Un CSV llega como texto; se tipifican las variables numéricas y se conservan como texto las tasas para no perder el formato original.
R11	Codificación de texto en archivo plano (OMS)	Year, Disease, Country, iso2, iso3, unsd_region, who_region	Data Conversion a Unicode DT_WSTR (50 o 250 según el campo).	Los nombres de países y regiones pueden incluir caracteres especiales que Unicode conserva.


Diseño Data Flow y Control Flow

El paquete contiene tres Data Flow Task, uno por fuente. No tienen restricciones de precedencia entre sí porque cargan tablas de staging independientes, de modo que SSIS puede ejecutarlos en paralelo. Todos están conectados a la misma base, los dos flujos que leen CSV utilizan además un administrador de conexiones de archivo plano.



Data Flow Task	Fuente	Función
Carga Staging y Perfil Clínico	Tabla dbo.stg_perfil_clinico	Depura, deduplica y valida el perfil clínico; separa registros atípicos.
SIVIGILA Nacional y Cundinamarca	CSV nacional y de Cundinamarca	Tipifica las columnas y carga el staging regional.
Datasets Globales	CSV de brotes de la OMS	Convierte a Unicode y carga el staging de brotes.


La base se organizó en tres zonas lógicas, como se puede observar.




Zona	Tablas	Propósito
Staging (datos crudos)	stg_perfil_clinico stg_regional_cundinamarca stg_oms_brotes	Copia fiel de la fuente. Permite auditar y repetir el proceso sin volver a leer los archivos originales.
Final (datos aceptados)	tbl_perfil_clinico_final	Registros únicos, estandarizados y con valores dentro de rango.
Revisión de calidad	tbl_revision_calidad	Registros atípicos separados para su revisión manual, con su valor original.

Data Flow Perfil Clínico

Es el flujo principal. Lee el staging, elimina duplicados, deriva columnas limpias y bifurca los registros según su validez.



Componente	Función en el flujo	Problemas que atiende
OLE DB Source	Lee dbo.stg_perfil_clinico (zona de staging).	Punto de partida repetible.
Sort	Ordena y elimina filas duplicadas.	R1
Derived Column	Crea seis columnas limpias y tipificadas.	R2 – R5, R7 – R9
Conditional Split	Separa válidos (0–110 años) de atípicos.	R6
OLE DB Destination	Carga registros válidos en tbl_perfil_clinico_final.	Salida aceptada
OLE DB Destination 1	Carga registros atípicos en tbl_revision_calidad.	Salida a revisión




Así fue como se configuró el OLE DB SOURCE, que extrae los registros desde staging y no desde el archivo original. Como el dato crudo nunca se modifica, el proceso puede repetirse cuantas veces sea necesario partiendo de la misma base.


Parámetro	Valor configurado
Administrador de conexiones OLE DB	.SQLEXPRESS.DB_ENFERMEDADES_ETV
Modo de acceso a datos	Tabla o vista
Nombre de la tabla o vista	[dbo].[stg_perfil_clinico]

Luego se seleccionan las columnas que definen la clave de ordenación y se activa la opción eliminar filas con valores de ordenación duplicados. Con esta opción el componente pasa de 1.377.630 filas de entrada a 729.765 de salida, es decir, retira 647.865 filas repetidas.



Luego viene el derived column.



Este calcula columnas nuevas mediante expresiones sobre las columnas de entrada. Todas se crean con la opción <add as new column>, por lo que las columnas originales se conservan. Combina limpieza de nulos, normalización de texto y conversión de tipos en un único paso.




Ahora el conditional que enruta cada fila a una salida según una condición. Las filas que cumplen la regla siguen a la tabla final; las demás, incluidas aquellas con edad, caen en la salida por defecto y van a revisión. Ninguna fila se descarta.




Y ya por último el destino de los datos válidos y los inválidos, la carga rápida inserta en bloque en lugar de fila por fila, lo que es esencial con ~730 mil registros. El bloqueo de tabla acelera la inserción y comprobar restricciones hace que la base valide sus reglas de integridad al cargar.


Para el otro dataflow, este lee el archivo plano, tipifica las columnas con Data Conversion y carga el resultado en staging.




Este crea una copia de cada columna con el tipo, longitud y página de códigos indicados, sin modificar la original. Un archivo CSV entrega todo como texto; aquí anio y conteo pasan a entero para poder agregarse.



Luego este sigue la misma estructura, pero convierte todas las columnas a Unicode.



Para este el uso de DT_WSTR conserva caracteres especiales de nombres de países y regiones. Los datos se dejan como texto en staging para preservar el original; su tipificación se hará al pasar a una tabla analítica.




El tratamiento se construyó en tres iteraciones. En cada una se ejecutó el paquete, se verificó el balance $\text{Recibidos} = \text{Aceptados} + \text{Duplicados} + \text{Enviados a revisión}$ y se usaron los hallazgos para definir los ajustes de la siguiente. La Iteración 3 corresponde a la versión final documentada en las secciones 3 y 4.

Se añade Sort tras el OLE DB Source. Se compara el conteo de entrada y salida para cuantificar los duplicados y se verifica que la diferencia esté explicada.

Con los duplicados resueltos, persistían valores de EDAD fuera de un rango plausible en la salida aceptada. Se agrega el Conditional Split y el destino tbl_revision_calidad, de modo que los atípicos se separen conservando su valor original.

Pusimos destinos válidos y de revisión, más los flujos SIVIGILA y OMS con Data Conversion. Las capturas siguientes muestran la ejecución con todos los componentes en verde.



Flujo	Recibidos	Aceptados	Duplicados eliminados	A revisión	Balance
Perfil clínico	1.377.630	729.758	647.865	7	$729.758 + 647.865 + 7 = 1.377.630 \checkmark$
SIVIGILA	1.640	1.640	n/a (sin Sort)	0	$1.640 = 1.640 \checkmark$
OMS	3.566	3.566	n/a (sin Sort)	0	$3.566 = 3.566 \checkmark$

En el perfil clínico, 1.377.630 filas entraron y todas están explicadas: 729.758 se aceptaron, 647.865 se eliminaron como duplicadas en el Sort y 7 se enviaron a revisión. En SIVIGILA y OMS, el número de filas es idéntico en la fuente, la conversión y el destino, por lo que no hubo pérdidas. Ningún componente registró errores de conversión, ya que todas las filas completaron el recorrido.

Manejo de Errores

Situación	Componente	Tratamiento
Registros duplicados	Sort	Se eliminan del flujo y se contabilizan (647.865). El original persiste en stg_perfil_clinico.
Edad fuera de 0–110 o nula	Conditional Split	Salida por defecto <i>Registros_Atipicos</i> → tbl_revision_calidad (7 registros); no se descartan.
Fallo de conversión de tipo (p. ej. EDAD no numérica)	Derived Column / Data Conversion	La pestaña «Salida de error» permite fallar el componente o redirigir la fila. En la ejecución final no hubo filas con error: todas completaron el flujo.
Posible truncamiento por longitud	Data Conversion / Destinos	Longitudes definidas de forma explícita (10, 20, 50, 100, 250) para cada campo.


Advertencias de validación (triángulo amarillo)	OLE DB Destination y Dest_Stg_OMS_Brotes	No impidieron la ejecución exitosa. Suelen deberse a diferencias de metadatos entre la columna de entrada y la del destino; se revisarán en el mapeo.
--	---	--

Tratamiento de los Registros de Revisión

- **Criterio de envío:** Edad fuera del intervalo 0–110 años o nula (regla R6).
- **Conservación del valor original:** Como las columnas derivadas son nuevas, el valor original de EDAD sigue disponible en el flujo y se carga en tbl_revision_calidad sin modificaciones.
- **Motivo:** La condición del Conditional Split define un motivo único para esta. Se recomienda persistirlo en una columna motivo_revision y la fecha de carga, de modo que la tabla sea autoexplicativa.
- **Ciclo de revisión:** Un responsable analiza los 7 registros, decide si corrige la fuente, acepta el valor o lo descarta de forma documentada, y el proceso puede repetirse desde staging.

Comparación de Calidad

Destino de los 1.377.630 registros recibidos del perfil clínico



Indicador de calidad	Datos originales (staging)	Resultado final	Mejora
----------------------	-------------------------------	-----------------	--------

Registros	1.377.630	729.758 aceptados + 7 en revisión	Base depurada y trazable
Unicidad – registros duplicados	647.865 (47,03 %)	0 (0 %)	–100 % de duplicados
Validez – edad fuera de 0–110	7 (0,001 % de los únicos)	0 en la tabla final	Atípicos aislados en revisión
Tasa de aceptación sobre registros únicos	—	99,999 % (729.758 de 729.765)	Alta calidad de partida
Consistencia de tipo – EDAD	Texto	Entero de 4 bytes (edad_int)	Permite cálculo y rangos
Consistencia de formato – SEXO / RÉGIMEN	Mayúsculas, espacios y nulos variables	TRIM + UPPER y reemplazo de nulos	Categorías unificadas
Texto con longitud definida	Sin control	10 / 20 / 50 / 100 / 250 y code page 1252	Sin truncamientos silenciosos
Pérdida sin explicación	—	0 registros	Balance cuadrado en los 3 flujos

Nota: el indicador de duplicados se calcula como la diferencia entre las filas de entrada y de salida del Sort dentro del mismo lote.

Antes y Después de los Datos

Regla	Antes (staging)	Después (tabla final / revisión)
R4 – Formato de SEXO	« f » (minúscula con espacios)	F

R2 – Nulo en SEXO / RÉGIMEN	NULL	Valor de reemplazo definido en la expresión
R5 – Tipo de EDAD	'045'	45 (entero)
R6 – Edad atípica	250	No entra a la tabla final; va a tbl_revision_calidad con el valor 250
R1 – Duplicados	Mismo registro repetido n veces	Una sola fila en la tabla final

Si se vuelve a ejecutar el paquete con el mismo lote no debe agregar filas repetidas a las tablas de destino.

Conclusiones

El paquete separa claramente tres zonas: staging (dato crudo), tablas finales (dato aceptado) y revisión (dato dudoso), lo que garantiza trazabilidad y repetibilidad.

- De 1.377.630 registros del perfil clínico, 729.758 (52,97 %) se aceptaron, 647.865 (47,03 %) eran duplicados y 7 se enviaron a revisión; el balance cuadra sin pérdidas sin explicación.
- SIVIGILA (1.640 filas) y OMS (3.566 filas) se cargaron íntegramente a staging con los tipos convertidos.
- Las tres iteraciones permitieron incorporar de forma gradual la estandarización, la de duplicación y la validación de rangos, justificando cada ajuste con los hallazgos de la ejecución previa.
- Los pendientes de la sección 7 (claves del Sort, catálogos con Lookup, advertencias de destinos) definen el siguiente ciclo de mejora.

Github

<https://github.com/Manmurcia/NexoBio-ETV/tree/main>

Página Web